

# Utjecaj distribucije podataka na vjerojatnost pokrivanja $t$ -intervala pouzdanosti za sredinu populacije

Projekt iz kolegija Računarska statistika (zadatak 5.)

Luka Šimek

Prirodoslovno-matematički fakultet — Matematički odsjek  
Sveučilište u Zagrebu

11. siječnja 2025.

1 Pojmovi

2 Zadatak

3 Rezultati

$$\gamma_1 = \mathbb{E} \left( \frac{X - \mathbb{E}X}{\text{Var}X} \right)^3 \quad \text{i} \quad \gamma_2 = \mathbb{E} \left( \frac{X - \mathbb{E}X}{\text{Var}X} \right)^4 - 3$$

Ako je  $X \sim N(\mu, \sigma)$  i  $X_1, X_2, \dots, X_n$  slučajni uzorak, tada je

$$\frac{\bar{X}_n - \mu}{S_n} \sqrt{n} \sim t(n-1),$$

pri čemu je  $S_n$  uzoračka varijanca. Iz toga dobivamo pouzdani interval ( $t$ -interval) pouzdanosti  $1 - \alpha$  za sredinu populacije  $\mu$  kao

$$\bar{X}_n \pm \frac{S_n}{\sqrt{n}} t_{\frac{\alpha}{2}, n-1}.$$

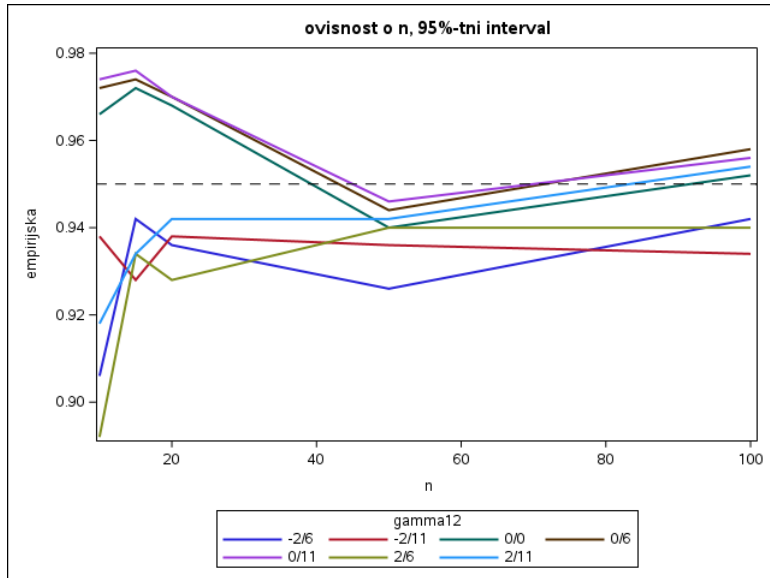
Pitanje: vrijedi li slični rezultat ako  $X$  nije normalno distribuirana?

MC studiju provodimo po kombinacijama faktora:

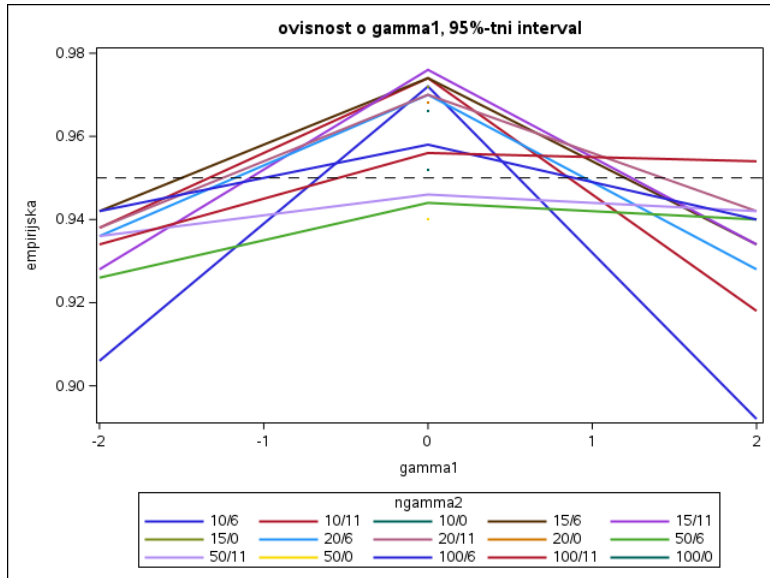
- duljina uzorka  $n = 10, 15, 20, 50, 100$
- $\gamma_1 = -2, 0, 2$
- $\gamma_2 = 0, 6, 11$
- $\mu = 0, \sigma = 5$

Za svaku trojku  $(n, \gamma_1, \gamma_2)$  simuliramo 500 uzoraka duljine  $n$ . Na temelju njih procjenjujemo stvarnu vjerojatnost pokrivanja nominalno 90%-p.i. i 95%-p.i.


# Ovisnost o $n$



# Ovisnost o $\gamma_1$



# Ovisnost o $\gamma_2$



- problematične su nesimetrične distribucije, naročito s malim uzorcima
- za simetrične spljoštene distribucije rezultati su slični kao za normalnu